Easy Finances AI

Model Evaluation & Tradeoff Analysis

Francesco Castagnozzi, Vincenzo Mauro

20/03/2026

Sommario

1 Introduzione **4**

2 Osservazioni sui dati **4**
2.1 Origine e struttura dei dati 4
2.2 Autocorrelazioni e feature di volatilità 5

3 Data Pre-processing & Feature Engineering **7**
3.1 Data Pre-processing 7
3.1.1 Pulizia del dataset 7
3.1.2 Conservazione e arricchimento dei dati 8
3.2 Feature Engineering 8

4 Risultati dell'esperimento **9**
4.1 Regressione 9
4.1.1 KNN Regressor 9
4.1.2 Gradient Boosting Regressor 11
4.1.3 Random Forest Regressor 12
4.2 Classificazione 13
4.2.1 Decision Tree 13
4.2.2 Gaussian Naive Bayes 16
4.2.3 Random Forest 18

5 Riflessioni e conclusioni **20**

link repository Github del progetto:
https://github.com/Memento0Mori/easy-finances-AI/tree/main

questa pagina è intenzionalmente lasciata vuota

1 Introduzione

In questo documento verranno presentati i risultati numerici e grafici dei nostri esperimenti, verranno analizzati i dati e le performance ottenute dalle previsioni dei vari modelli, analizzate le scelte logiche e strutturali e l'ingegneria delle feature effettuata, nonché il processing dei dati.

2 Osservazioni sui dati

2.1 Origine e struttura dei dati

Tutti i modelli usano lo stesso dataset per evitare varianze nelle predizioni e per comparare meglio i diversi approcci e risultati. Dal database di Yahoo Finance, disponibile con la libreria *yfinance* di Python, sono stati raccolti i dati giornalieri relativi all'andamento in borsa di varie aziende (come Apple e Meta) nell'arco temporale compreso tra il 2015 e il 2025, di questi dati sono stati considerati i dati OHCLV (definiti nel documento M.E.T.A.D.) per derivarne le feature standard utilizzate nel dominio finanziario.

Date	Close	High	Low	Open	Volume
2015-01-02	24.214888	24.682220	23.776348	24.671145	212818400
2015-01-05	23.532722	24.064285	23.346676	23.984551	257142000
2015-01-06	23.534937	23.794073	23.173916	23.596952	263188400
2015-01-07	23.864948	23.964616	23.632389	23.743131	160423600
2015-01-08	24.781893	24.839479	24.075357	24.192745	237458000

Esempio di variabili OHCLV ottenute dai dati in borsa di Apple

2.2 Autocorrelazioni e feature di volatilità

Nei notebook è stata condotta un'analisi delle auto-correlazioni, sia sulla serie dei prezzi sia sui rendimenti, che costituiscono una rappresentazione più adatta per lo studio delle dinamiche di dipendenza temporale.
Possiamo notare un panorama generale delle correlazioni tra feature grazie alla correlation matrix seguente.

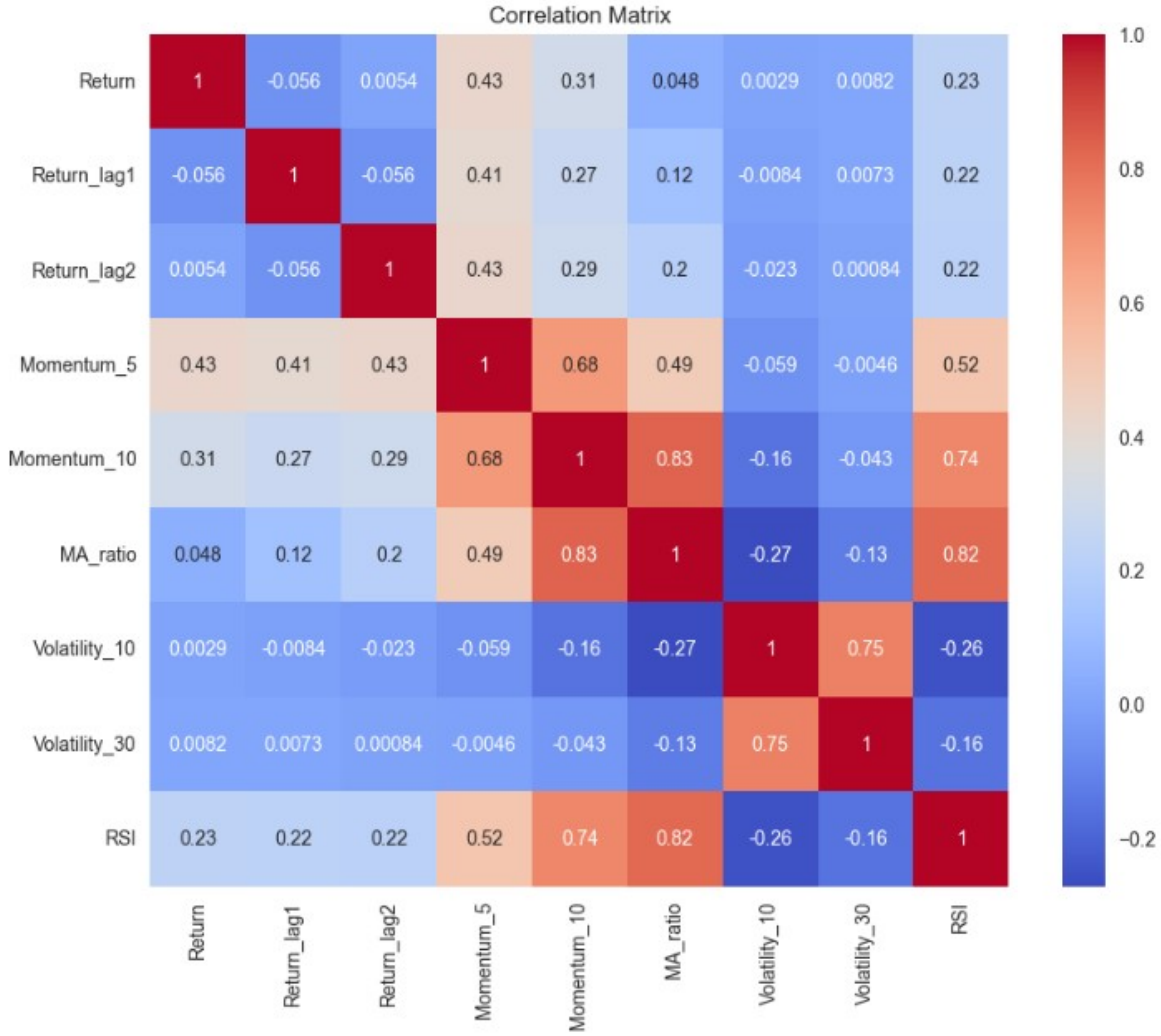

Dai grafici ACF (Autocorrelation Function) e PACF (Partial Autocorrelation Function) vediamo come i rendimenti presentano una autocorrelazione generalmente debole e limitata ai primi lag gioprnalieri, fenomeno coerente con l'ipotesi di efficienza debole dei mercati finanziari, ma che conferma la presenza elevata di rumore e la difficoltà di predizione intrinseche del mercato.

In particolare, eventuali picchi nei primi ritardi suggeriscono la presenza di una minima dipendenza a breve termine, che può essere sfruttata dai modelli, ma che tende a dissolversi rapidamente.

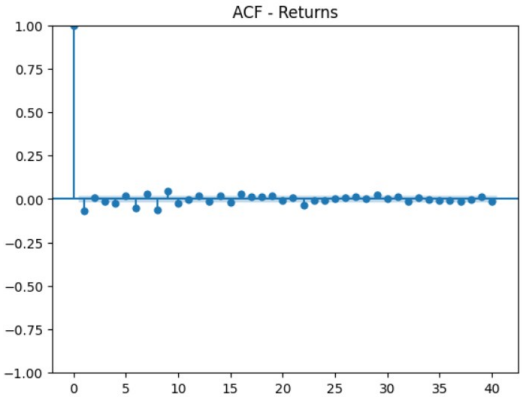

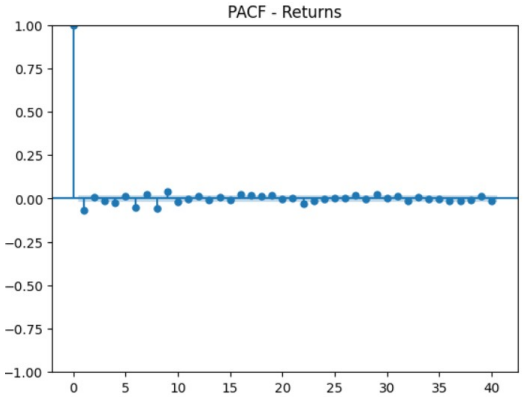

Un aspetto più rilevante emerge invece osservando le misure di volatilità nel tempo: il grafico della volatilità rolling (ad esempio deviazione standard su finestra mobile di 20 giorni) evidenzia chiaramente un fenomeno di volatility clustering, ovvero l'alternanza tra periodi caratterizzati da bassa variabilità e fasi in cui le oscillazioni dei prezzi risultano molto più ampie.

Come si può immaginare, durante fasi ad alta volatilità, gli errori di previsione tendono ad aumentare, soprattutto per modelli più semplici o lineari, come possiamo vedere nel segunete grafico di rolling volatility percepita su un range di 20 gg.

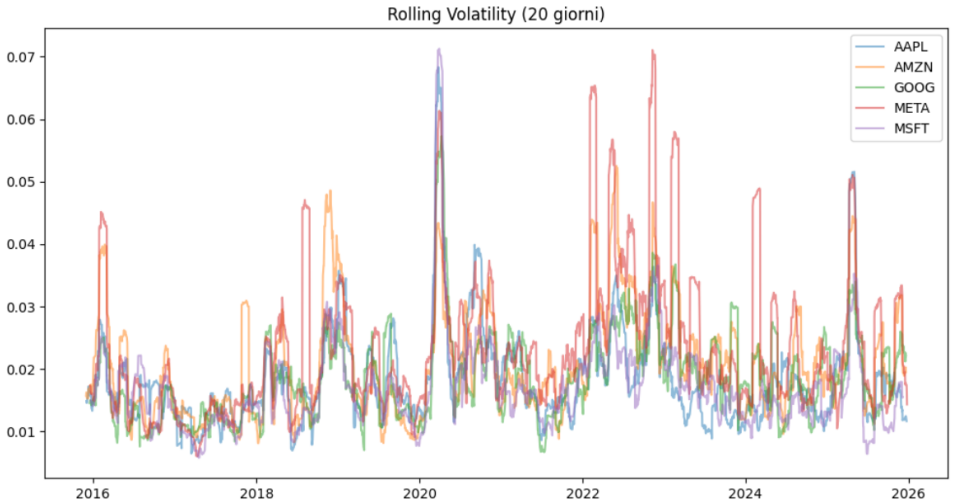

Dal punto di vista applicativo, l'inclusione di feature legate alla volatilità all'interno del dataset permette ai modelli di "contestualizzare" le predizioni, distinguendo tra situazioni di mercato stabile e instabile, e contribuendo quindi a migliorare la capacità predittiva complessiva.
Inoltre, la presenza di volatilità non costante suggerisce che una semplice modellazione statica potrebbe non essere sufficiente: modelli o strategie che tengano conto della dinamica temporale (anche tramite feature) risultano più adatti rispetto a approcci puramente globali.

Infine, dall'analisi combinata di autocorrelazione e volatilità riusciamo a notare come una bassa autocorrelazione implica che il segnale predittivo è debole, mentre il clustering della volatilità indica che gli errori non sono distribuiti uniformemente nel tempo, ma concentrati in specifici intervalli.

3 Data Pre-processing & Feature Engineering

La qualità delle feature e il pre-processing effettuato sul dataset influiscono notevolmente le performance dei modelli, infatti, i dati OHCLV anche se contengono informazioni importanti non sono sufficienti a catturare tutti gli aspetti delle dinamiche di mercato.

Con l'obiettivo di arricchire il dataset e renderlo più adatto all'apprendimento dei modelli, abbiamo eseguito le seguenti operazioni.

3.1 Data Pre-processing

3.1.1 Pulizia del dataset

Per diminuire la presenza di bias e aumentare coerenza e stabilità nelle previsioni è stata effettuata una pulizia del dataset, assicurandosi che non vi siano dati mancanti o valori anomali.
Il dataset è stato poi migliorato nel corso degli esperimenti effettuati per evitare rumore eccessivo nei dati e migliorare la stabilità delle previsioni.

Le versioni del dataset utilizzate negli esperimenti sono 3:

- **Dataset supervisionato:** il dataset originale è stato adattato alle feature utilizzate nelle previsioni dei modelli, questo ha permesso di aumentare l'accuratezza e la stabilità delle previsioni.
- **Dataset filtrato v1 (treshold: 0.01%):** è stata applicata una threshold, un filtro, sul dataset supervisionato in modo da escludere tutti i movimenti giornalieri di return inferiori/superiori al $\pm$ 0.01%, riducendo di fatto il rumore nei dati che confonderebbe i modelli in fase di training.
- **Dataset filtrato v2 (treshold: 0.02%):** per lo stesso motivo del precedente dataset, è stata impostata la treshold in modo da escludere i movimenti inferiori/superiori al $\pm$ 0.02%, analizzando il comportamento dei modelli in un dataset più pulito, ma con meno dati disponibili sul quale effettuare le predizioni.

3.1.2 Conservazione e arricchimento dei dati

Per fornire una rappresentazione assoluta dei prezzi, e quindi più adatta all'analisi statistica, è stato effettuato il calcolo dei rendimenti percentuali giornalieri partendo dal prezzo di chiusura.

Inoltre, poiché i dati finanziari sono sequenziali, è stato conservato l'ordine cronologico delle osservazioni, a cui è stato adottato uno split temporale (come specificato nel M.E.T.A.D. - sezione 2.2: "strategia di split"), in modo da evitare mescolamenti casuali che avrebbero portato a fenomeni di data leakage.

Infine le feature sono state normalizzate per favorire le predizioni del KNN Regressor, sensibile alla scala delle variabili.
Lo scaling è stato effettuato esclusivamente sul training set e successivamente applicato al test set, in modo da preservare la validità del processo di valutazione.

3.2 Feature Engineering

L'introduzione di feature diverse ha permesso di catturare pattern caratteristici delle serie finanziare, approfondendo così l'apprendimento dei modelli e migliorando le capacità predittive di ognuno.

Modelli come il KNN Regressor beneficiano di feature ben scalate e informative, poiché la distanza tra osservazioni diventa più rappresentativa della reale similarità tra situazioni di mercato.
Il Gradient Boosting Regressor sfrutta queste feature per modellare relazioni non lineari e interazioni complesse, migliorando sensibilmente le performance rispetto a modelli più semplici.

Nei task di classificazione, feature come RSI e volatilità contribuiscono a rendere più separabili le classi (up/down), migliorando metriche come precision e recall.
Tuttavia, l'introduzione di molte feature aumenta anche il rischio di overfitting, influenzando direttamente la qualità delle predizioni e la capacità di generalizzazione dei modelli, questo rende fondamentale il controllo della complessità dei modelli e l'introduzione di poche ma efficaci features.

4 Risultati dell'esperimento

4.1 Regressione

4.1.1 KNN Regressor

Il KNN Regressor rappresenta la baseline non parametrica del nostro progetto ed è basato su un approccio locale: la predizione viene effettuata come media dei K vicini più prossimi nello spazio delle feature.
Questa natura rende il modello semplice e intuitivo, ma fortemente dipendente dalla distribuzione dei dati e dalla scala delle variabili, anche le metriche evidenziano come il modello possiede una capacità limitata nel catturare la variabilità del target.

- **MAE:** 0.0127963
- **RMSE:** 0.0179892
- **MSE:** 0.00323614

In particolare, l'RMSE relativamente elevato indica che il modello fatica a gestire errori più marcati, tipicamente associati ai movimenti improvvisi del mercato.
Questo comportamento è coerente con la struttura del KNN, che tende a produrre predizioni generali, riducendo l'impatto degli outlier ma perdendo reattività nei cambiamenti più bruschi.

Nel grafico seguente si osserva chiaramente come la curva predetta segua l'andamento generale del target ma con oscillazioni attenuate, segno che il modello tende ad un generale underfitting nelle predizioni.

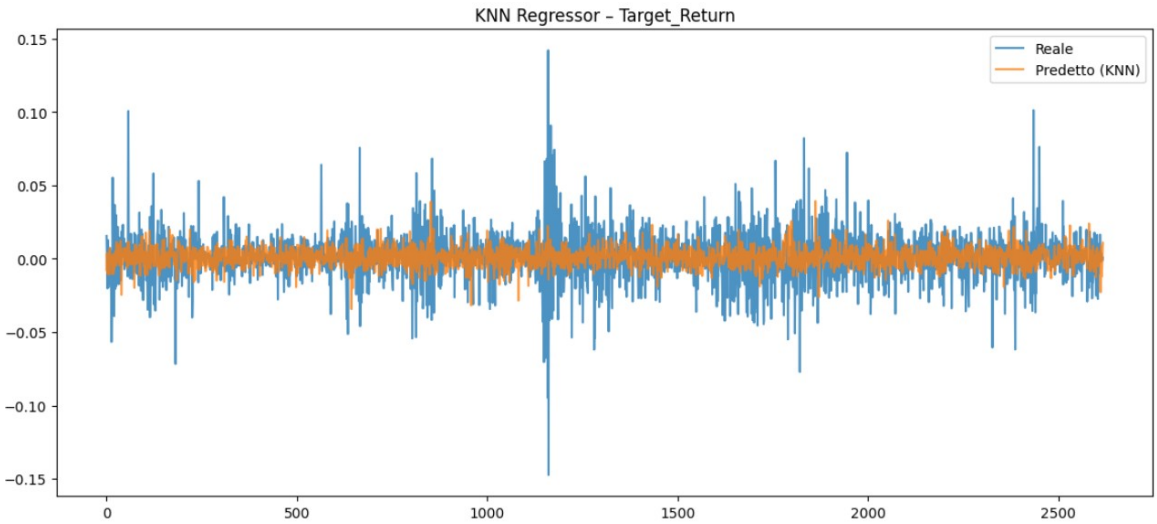

Inoltre, l'equity curve del KNN mostra una crescita complessiva nel tempo, ma caratterizzata da fluttuazioni e fasi di drawdown, suggerendo che il modello riesce a intercettare segnali utili solo in modo non sistematico.

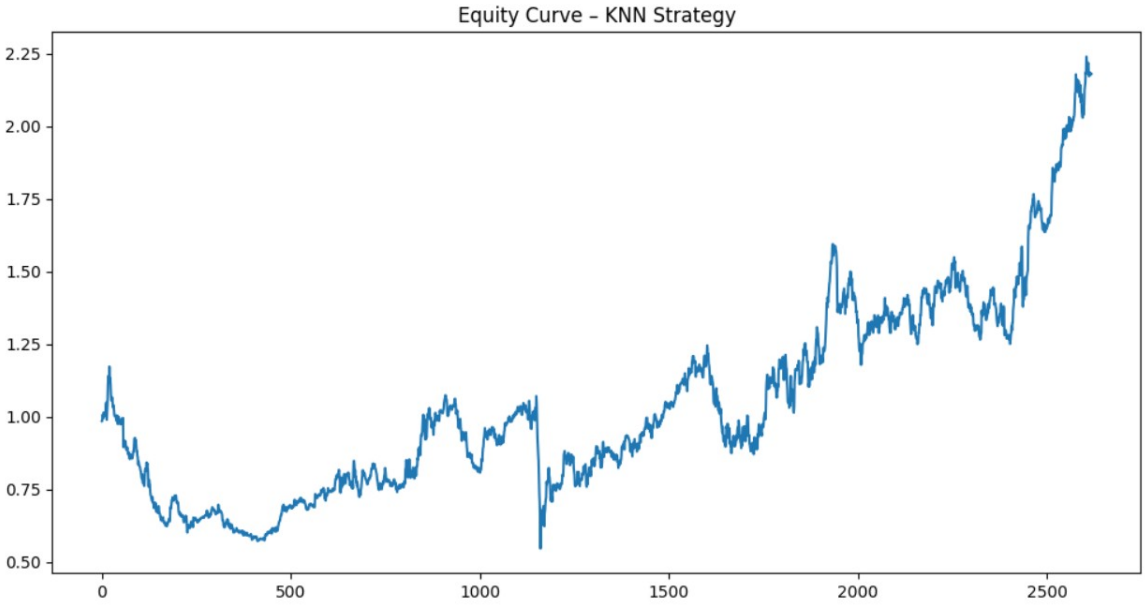

In conclusione, il KNN Regressor, pur rappresentando una baseline utile per comprendere il comportamento dei dati, si dimostra limitato in un contesto finanziario complesso.
Le metriche evidenziano una difficoltà strutturale nel gestire la variabilità del target e i grafici confermano una tendenza a produrre predizioni eccessivamente grossolane, portando a un modello poco reattivo e incline all'underfitting.

Il KNN può essere utile come riferimento iniziale, ma non rappresenta una soluzione adeguata per scenari reali in cui è richiesta sensibilità ai cambiamenti di mercato.

4.1.2 Gradient Boosting Regressor

Il Gradient Boosting Regressor costruisce una sequenza di modelli deboli (tipicamente alberi) in maniera iterativa, correggendo progressivamente gli errori dei modelli precedenti, consentendo di catturare relazioni complesse e non lineari tra le feature.
Questo è il modello più complesso utilizzato nel nostro progetto, e le metriche confermano come questo modello presenti i risultati migliori tra tutti i modelli testati nel contesto analizzato.

- **MSE:** 0.0002669
- **RMSE:** 0.0163366
- **R^2:** 0.0689122

La riduzione dell'errore e l'aumento del coefficiente di determinazione indicano una maggiore capacità di adattarsi ai dati, riuscendo a spiegare una quota più ampia della variabilità del target. Nonostante ciò, il valore di R^2 rimane relativamente basso, segno che il modello, pur essendo avanzato, fatica a modellare completamente la componente stocastica del mercato.

Nel grafico possiamo osservare come le predizioni seguano in modo più fedele l'andamento reale rispetto agli altri modelli, con una migliore capacità di adattarsi ai cambiamenti di trend, tuttavia, anche il Gradient Boosting tende a smorzare i picchi più estremi, suggerendo che, pur migliorando le performance, non elimina completamente le limitazioni legate alla natura rumorosa dei dati finanziari.

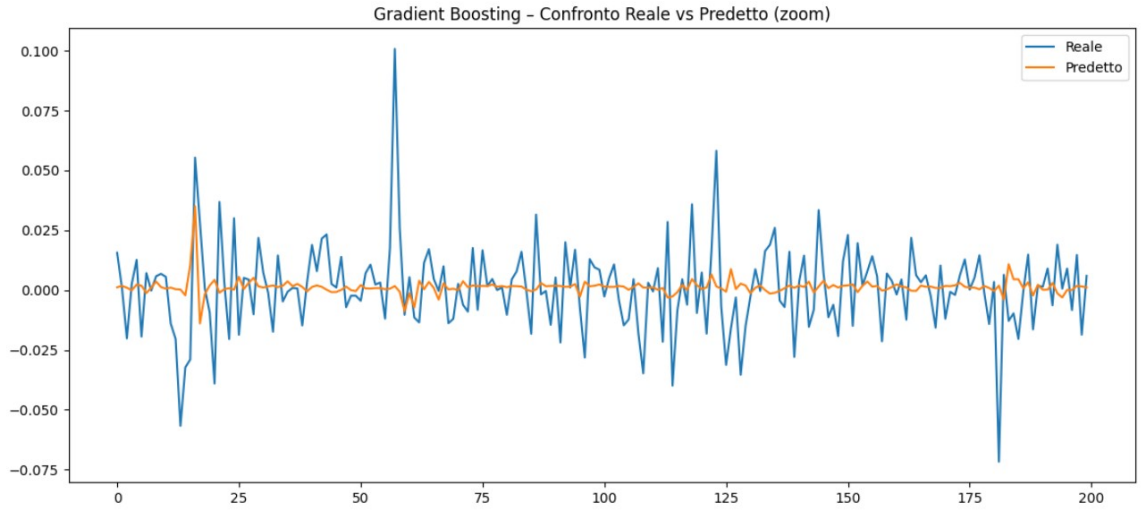

Il Gradient Boosting Regressor emerge quindi come il modello più efficace tra quelli analizzati, grazie alla sua capacità di apprendere in modo iterativo dagli errori e di modellare relazioni non lineari più complesse, nonostante ciò, anche questo modello non riesce a superare completamente i limiti imposti dalla natura rumorosa e non stazionaria dei dati finanziari.

In un'ottica progettuale, il Gradient Boosting Regressor rappresenta la scelta più solida tra i modelli testati, offrendo il miglior equilibrio tra accuratezza e capacità di generalizzazione, pur richiedendo attenzione nella gestione della complessità e del rischio di overfitting.

4.1.3 Random Forest Regressor

Come per la classificazione, abbiamo introdotto un approccio ensemble anche nel task di regressione, per comparare i risultati ottenuti in contesti ugali ma compiti differenti.
Le metriche ottenute mostrano un miglioramento rispetto alla baseline definita dal KNN:

- **MSE:** 0.0002747
- **RMSE:** 0.0166
- **R^2:** 0.0417

Il valore più basso di RMSE indica una riduzione dell'errore medio sulle predizioni, mentre l'R^2, seppur contenuto, segnala una maggiore capacità esplicativa del modello e segno di un lieve miglioramento nella precisione delle predizioni effettuate dal modello rispetto alla baseline.
Tuttavia, il valore ancora modesto di R^2 evidenzia come una parte significativa della variabilità del target rimanga indefinita, riflettendo la complessità intrinseca del problema.

Dal grafico di confronto tra valori reali e predetti, emerge come il modello riesca a seguire meglio il trend generale rispetto al KNN, mostrando una maggiore aderenza alla serie reale, tuttavia, anche in questo caso le predizioni risultano più regolari e meno reattive rispetto ai picchi della serie osservata, evidenziando una tendenza a sottostimare le variazioni più estreme.

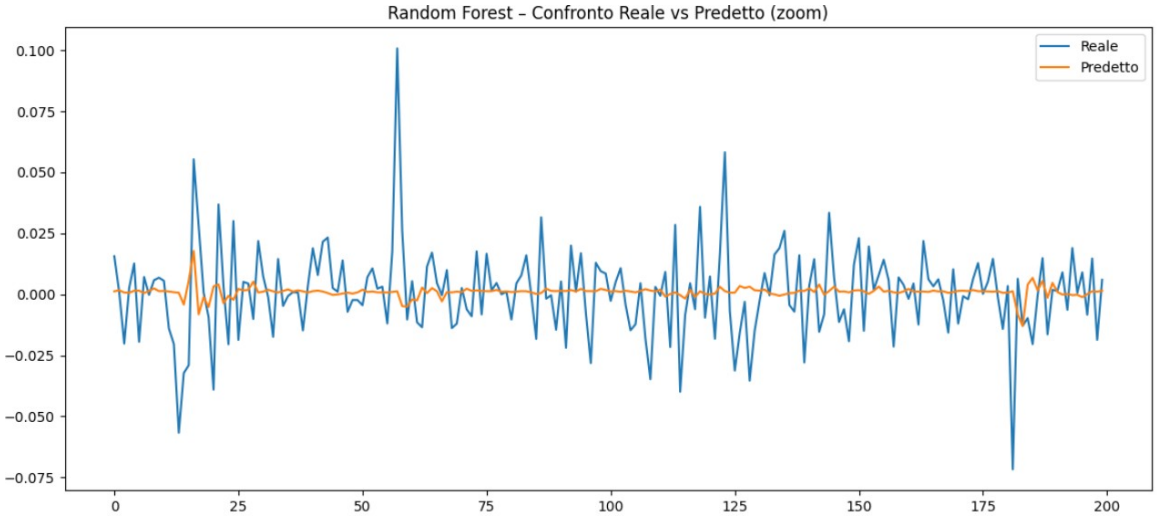

4.2 Classificazione

4.2.1 Decision Tree

	precision	recall	f1-score	support
0	0.49	0.24	0.32	2383
1	0.53	0.78	0.63	2622
accuracy			0.52	5005
macro avg	0.51	0.51	0.48	5005
weighted avg	0.51	0.52	0.48	5005

Dalla immagine del report di classificazione si evidenziano prestazioni complessivamente modeste del modello, con un'accuratezza pari al 52%, appena superiore al caso casuale, segno che il modello fatica a catturare pattern realmente informativi.

Analizzando le singole classi, emerge uno squilibrio nel comportamento:

Per la classe 1 (movimento up) il recall è elevato (78%), indicando che il modello riesce a identificare correttamente la maggior parte dei rialzi, ma a scapito della precision (53%), quindi con un numero significativo di falsi positivi.

Al contrario, per la classe 0 (movimento down), il recall è molto basso (24%), il che indica una scarsa capacità di riconoscere i ribassi.
L'F1-score riflette questo sbilanciamento, risultando decisamente migliore per la classe 1 (63%) rispetto alla classe 0 (32%).

Le medie macro e pesate confermano una performance poco equilibrata tra le classi, suggerendo che il modello tende a sovrastimare una direzione del mercato.

Le seguenti confusion matrix ci mostreranno diversi casi di test dove il Decision Tree opera rispettivamente sul dataset supervisionato, sul dataset con threshold impostata a 0.01% e sul dataset con threshold impostata a 0.02%: possiamo notare ciò che abbiamo appena descritto, un forte adattamento alla previsione, in particolare nei movimenti di up, ma una performance complessivamente di poco superiore alla casualità, performance scarse in un contesto di ML ma sufficienti per il nostro esperimento accademico.

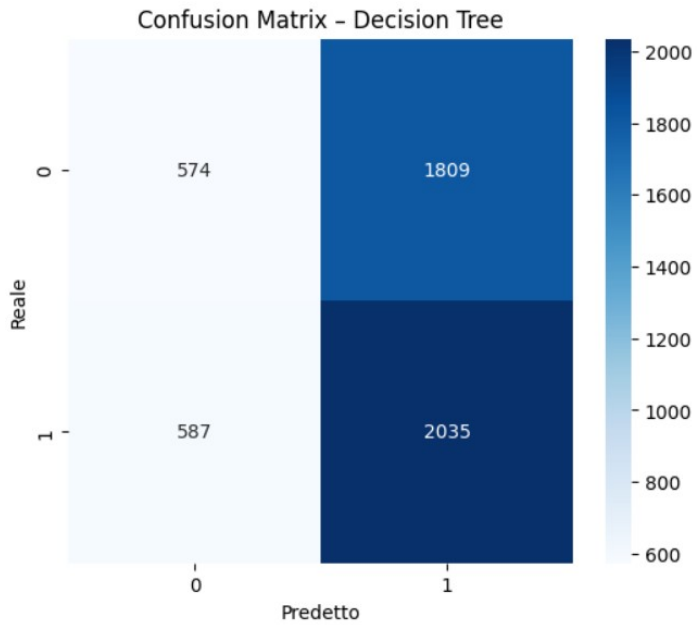

Decision Tree su dataset supervisionato - no threshold
Accuracy: 52.12%

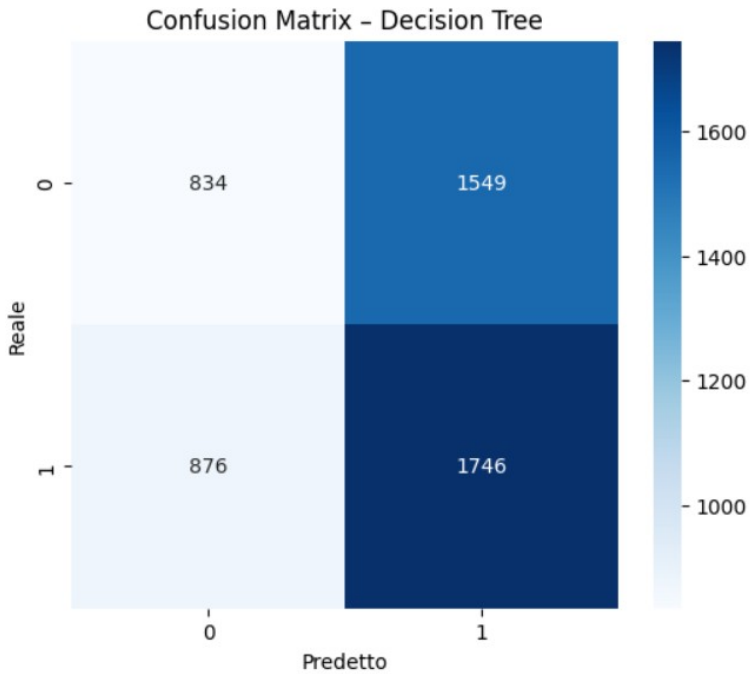

Decision Tree su dataset supervisionato - threshold impostata allo 0.01%
Accuracy:51.54%

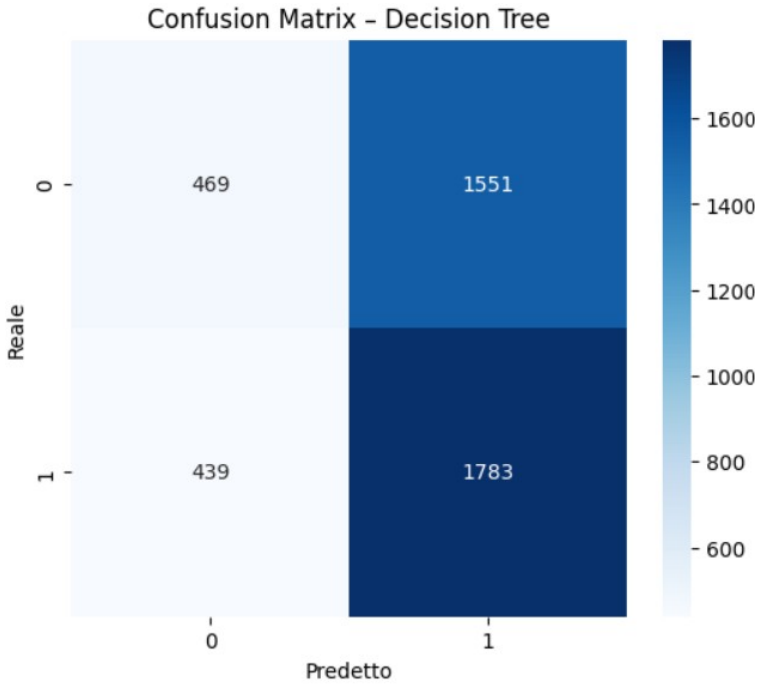

Decision Tree su dataset supervisionato - threshold impostata allo 0.02%
Accuracy: 53.08%

4.2.2 Gaussian Naive Bayes

	precision	recall	f1-score	support
0	0.51	0.30	0.38	2383
1	0.54	0.73	0.62	2622
accuracy			0.53	5005
macro avg	0.52	0.52	0.50	5005
weighted avg	0.52	0.53	0.50	5005

Sul Naive Bayes si può notare un leggero miglioramento rispetto al caso precedente, con un'accuratezza pari al 53%, comunque ancora vicina al comportamento casuale, indicando che anche questo modello cattura solo parzialmente la struttura dei dati.

Analizzando le singole classi, si osserva nuovamente uno sbilanciamento: la classe 1 presenta un recall elevato (73%), segno che il modello riesce a intercettare gran parte dei movimenti positivi, ma con una precision moderata (54%), quindi con diversi falsi positivi.

La classe 0, invece, continua a essere più difficile da modellare, con un recall basso (30%), indicando che molti ribassi non vengono correttamente identificati.
Riscontriamo questa difficoltà anche negli F1-Score, risultando più alto per la classe 1 (62%) rispetto alla classe 0 (38%).

Le medie macro e pesate, molto vicine al 50%, confermano una performance complessiva ancora poco equilibrata, evidenziando una tendenza del modello a privilegiare una direzione del mercato, comportamento critico in un contesto finanziario dove la corretta identificazione di entrambe le classi è fondamentale.

In questo caso le confusion matrix mostrano diversi casi di test dove il Naive Bayes opera rispettivamente sul dataset supervisionato e sul dataset con threshold impostata a 0.02%.

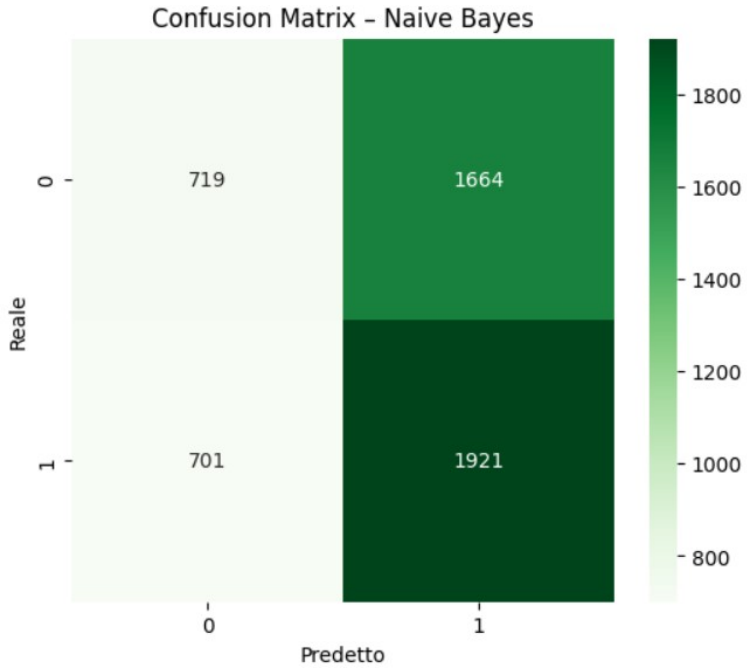

Naive Bayes su dataset supervisionato - no threshold
Accuracy:52.74%

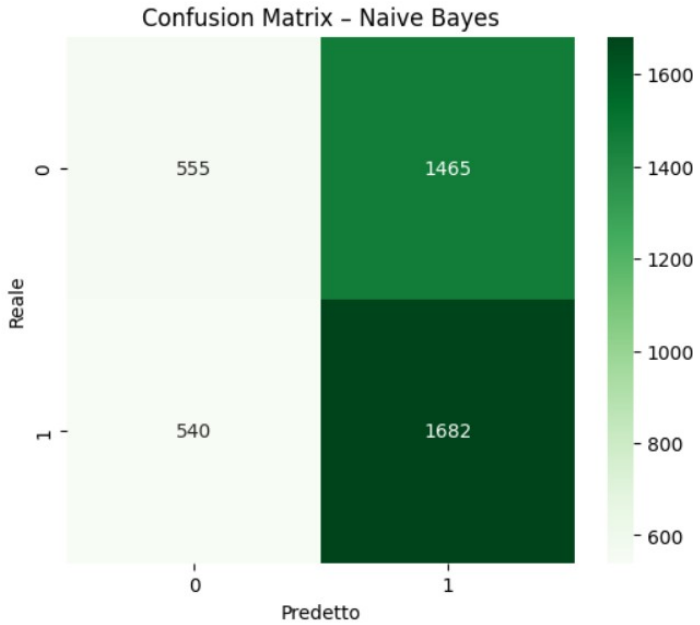

Naive Bayes su dataset supervisionato - threshold impostata allo 0.02%
Accuracy: 52.73%

4.2.3 Random Forest

I risultati del Random Forest mostrano un comportamento molto simile ai modelli precedenti, con un'accuratezza che si mantiene stabile attorno al 52–53% in tutti gli scenari testati, in particolare, nel primo test sul dataset supervisionato senza threshold si osserva un'accuracy pari a 52%, mentre l'introduzione di feature ingegnerizzate e soglie decisionali porta a un modestissimo miglioramento: 52.5% nel secondo test e 52.4% nel terzo, seppur considerando che quest'ultimo ha ricevuto una limitazione sulla crescita massima della foresta decisionale.

Questo indica che la Random Forest riesce a beneficiare, seppur in modo limitato, dell'arricchimento informativo del dataset, inoltre, questi risultati suggeriscono che il modello, pur essendo più robusto e stabile rispetto a un singolo Decision Tree grazie all'aggregazione di più alberi, non riesce comunque a superare in modo significativo la soglia della casualità.

Di seguito possiamo analizzare le confusion matrix dei casi di test dove il modello opera sul dataset supervisionato, sul dataset con threshold impostata a 0.02% e la confusion matrix del test sul dataset con threshold al 0.01% ma con dimensione limitata sulla crescita della foresta decisionale.

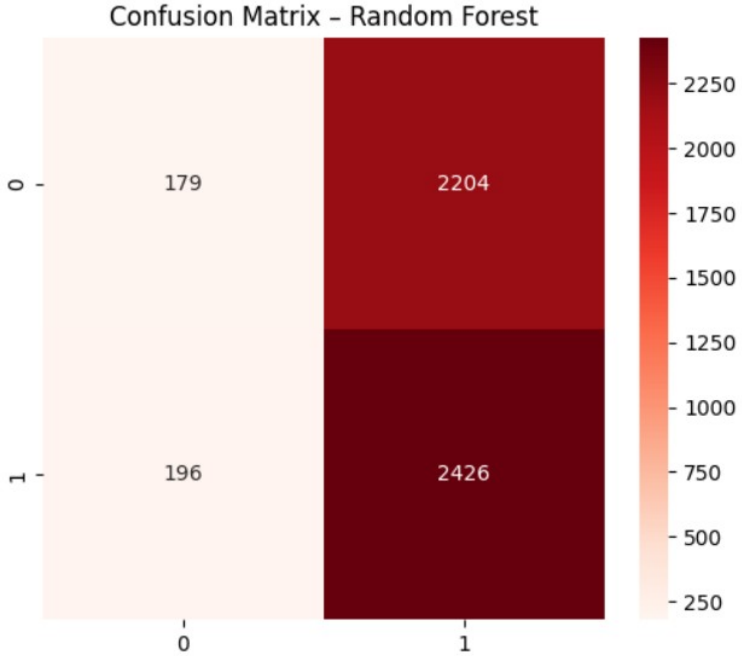

Random Forest su dataset supervisionato - no threshold
Accuracy:52.04%

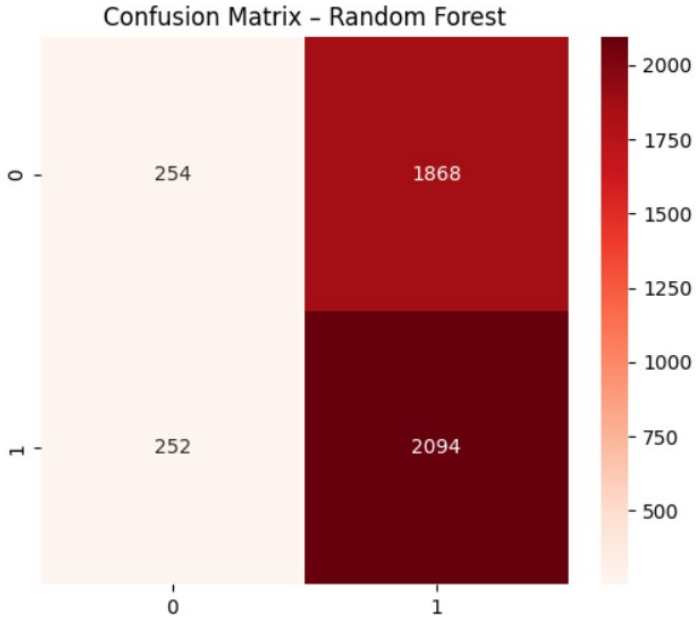

Random Forest su dataset supervisionato - threshold impostata allo 0.02%
Accuracy:52.55%

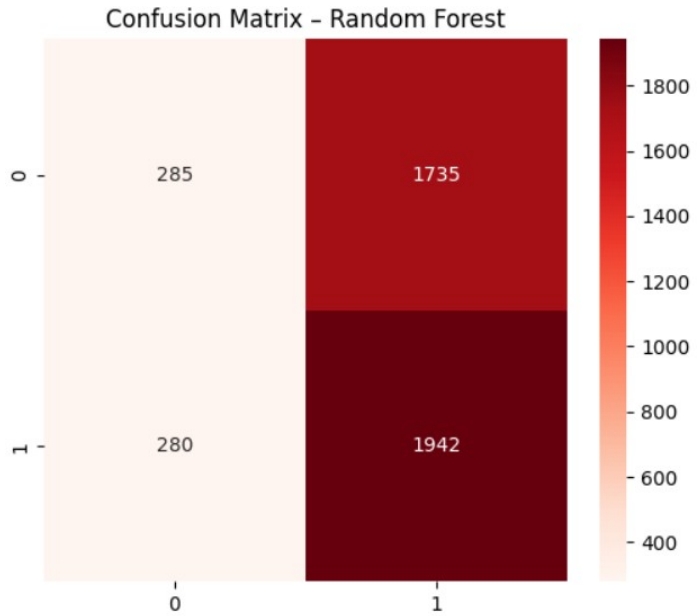

Random Forest su dataset supervisionato - threshold impostata allo 0.01% e dimensione ridotta
Accuracy:52.49%

Il guadagno introdotto dalle nuove feature e dall'uso di threshold è marginale, segno che il limite principale non risiede tanto nella capacità del modello, quanto nella difficoltà intrinseca del problema predittivo.

La Random Forest rappresenta un miglior compromesso tra varianza e bias, ma i risultati evidenziano come, in un contesto finanziario rumoroso e non stazionario, anche modelli più sofisticati fatichino a ottenere performance significativamente superiori.

5 Riflessioni e conclusioni

I risultati ottenuti nel corso degli esperimenti mettono in evidenza la complessità intrinseca del problema della previsione nei mercati finanziari.
Nonostante l'utilizzo di modelli appartenenti a approcci semplici e locali come il KNN fino a tecniche ensemble più sofisticate come Random Forest e Gradient Boosting, le performance complessive rimangono contenute, sia in termini di errore nella regressione che di accuratezza nella classificazione.

Dal punto di vista della regressione, i modelli più avanzati riescono effettivamente a migliorare le metriche rispetto alla baseline, ma il contributo esplicativo resta limitato, uesto suggerisce che una parte significativa della dinamica dei rendimenti non è catturabile attraverso le sole feature utilizzate, ma è invece dominata da fattori esterni, rumore e componenti imprevedibili.

In questo contesto, l'aumento della complessità del modello porta benefici marginali, senza riuscire a colmare il gap informativo presente nei dati.
Nel task di classificazione, la difficoltà risulta ancora più evidente: le performance si mantengono stabilmente prossime alla soglia della casualità, indicando che la previsione della direzione dei movimenti di mercato rappresenta un problema particolarmente ostico.

Anche modelli più robusti, come la Random Forest, non riescono a ottenere miglioramenti significativi, evidenziando come il limite principale non risieda tanto nella capacità dei modelli quanto nella natura stessa del fenomeno analizzato.
Un aspetto rilevante emerso trasversalmente è la difficoltà nel modellare correttamente le fasi di alta volatilità, tutti i modelli tendono infatti a produrre predizioni più regolari e conservative, sottostimando i movimenti più estremi.
Questo comportamento riflette le proprietà statistiche dei dati finanziari, caratterizzati da bassa autocorrelazione nei rendimenti e da fenomeni di clustering della volatilità, che rendono il segnale predittivo debole e instabile.

Nel complesso, il lavoro evidenzia come, in un contesto finanziario reale, l'efficacia dei modelli di machine learning sia fortemente limitata dalla qualità e dalla natura delle informazioni disponibili.
I risultati ottenuti non devono quindi essere interpretati come un fallimento dei modelli, ma piuttosto come un'analisi comparativa dei modelli e dei loro limiti operativi, fornendo una base solida per futuri sviluppi e miglioramenti.