Easy Finances AI

M.E.T.A.D.

Model Evaluation & Tradeoff Analysis Document

Francesco Castagnozzi, Vincenzo Mauro

gg/mm/aaaa

Sommario

1 Introduzione **5**
1.1 Definizione del problema predittivo e del contesto applicativo . . . 5
1.2 Definizione delle feature utilizzate . . . 5
1.2.1 Features aggiuntive . . . 6
1.3 Obiettivi della valutazione dei modelli . . . 7
1.3.1 Definizione delle metriche utilizzate . . . 7
1.3.2 Limiti delle metriche . . . 7

2 Protocollo sperimentale **8**
2.1 Setup sperimentale . . . 8
2.2 Strategia di split . . . 8
2.3 Riproducibilità dell'esperimento . . . 9
2.3.1 Ambiente sperimentale . . . 9
2.3.2 Librerie e strumenti utilizzati . . . 9
2.4 Struttura sperimentale . . . 10
2.5 Riproducibilità . . . 10

3 Confronto tra i modelli **11**
3.1 Selezione dei modelli e scelte strutturali . . . 11
3.1.1 Regressione . . . 11
3.1.2 Classificazione . . . 12
3.2 Criteri di confronto . . . 12
3.2.1 Accuratezza predittiva . . . 12
3.2.2 Stabilità e Robustezza . . . 12

4 Analisi degli errori **13**

5 Trade-off e Limiti **14**
5.1 Interpretabilità vs. Stabilità . . . 14
5.2 Semplicità vs. Accuratezza . . . 14

6 Riepilogo e Conclusioni **15**
6.1 Definizione del problema e del contesto applicativo . . . 15
6.2 Analisi delle metriche, delle feature e del dataset . . . 15
6.3 Analisi dei trade-off e limiti applicativi . . . 16
6.4 Sviluppi futuri . . . 16

link repository Github del progetto:
https://github.com/Memento0Mori/easy-finances-AI/tree/main

questa pagina è intenzionalmente lasciata vuota

1 Introduzione

1.1 Definizione del problema predittivo e del contesto applicativo

Lo scopo del progetto è analizzare il comportamento e i risultati di vari modelli di ML in un contesto complesso e dinamico, dove i dati analizzati non sono stazionari e presentano molto rumore.
In questo progetto useremo due approcci:

- Il primo **(regressione)** analizzerà i dati presenti nel dataset, fornendo delle predizioni sulla variazione percentuale giornaliera del prezzo di un titolo in borsa.
- Il secondo **(classificazione)** predirà la direzione del movimento in borsa (up/down), confronterà i risultati di vari modelli e valuterà, in base alle metriche di valutazione applicate, qual è il modello più adatto a questo tipo di previsione in questo specifico contesto.

1.2 Definizione delle feature utilizzate

I valori di apertura, massimo, minimo e chiusura delineano il range dei prezzi, mentre il volume quantifica la liquidità negoziata. Queste serie storiche di dati, che per comodità chiameremo OHLCV: "Open-High-Low-Close-Volume", rappresentano un'istantanea delle dinamiche di mercato per ogni giorno dell'intervallo di 10 anni e presentano pattern non identificabili dall'occhio umano.
Per questo utilizziamo modelli di ML per estrarre informazioni comunemente usate in analisi tecnica e in modelli predittivi finanziari, al fine di identificare correlazioni tra variabili storiche e futuri movimenti di prezzo.

I risultati saranno mostrati in maniera facilmente comprensibile tramite grafi e matrici di confusione che evidenziano la distribuzione degli errori e la correttezza delle predizioni effettuate.

1.2.1 Features aggiuntive

Inoltre, per aumentare le performance dei modelli, vengono introdotte le seguenti features, ricavate tutte da un periodo di 5 giorni consecutivi:

- **Momentum:** rappresenta una misura della velocità e della direzione con cui il prezzo di un asset varia nel tempo, in poche parole, indica se il prezzo sta continuando a muoversi nella stessa direzione.

  Questa feature aiuta a individuare trend e dinamiche temporali di breve periodo: un momentum positivo indica una fase di crescita del prezzo, mentre un momentum negativo indica una possibile fase discendente.

- **Medie mobili:** Le medie mobili rappresentano la media dei prezzi osservati in una finestra temporale definita (ad esempio 5, 10 o 20 giorni) e sono utilizzate per attenuare le fluttuazioni di breve periodo e mettere in evidenza il trend generale del prezzo, permettendo di attenuare l'effetto del rumore delle serie di dati.

  Questo porta a decisioni più sicure poiché la relazione tra il prezzo corrente e la sua media mobile può suggerire condizioni di possibile inversione o continuazione del trend.

- **Volatilità:** misura il grado di variabilità del prezzo nel tempo, rappresentando una stima del rischio associato a un asset: un'elevata volatilità indica che il prezzo subisce oscillazioni ampie e frequenti, mentre una volatilità più bassa segnala un comportamento più stabile.

  Questa informazione consente di distinguere periodi di mercato relativamente tranquilli da fasi più turbolente, aiutando i modelli ad affrontare una maggiore incertezza predittiva.

- **RSI (Relative Strength Index):** è un indicatore utilizzato nell'analisi tecnica che misura la velocità e l'intensità dei movimenti di prezzo su una scala compresa tra 0 e 100.

  Valori elevati di RSI indicano una forte domanda dell'asset nel mercato mentre valori molto bassi suggeriscono situazioni di forte offerta, fornendo un'informazione sintetica sullo stato del mercato e contribuendo a identificare possibili punti di inversione del trend.

1.3 Obiettivi della valutazione dei modelli

1.3.1 Definizione delle metriche utilizzate

Nella fase di valutazione, l'obiettivo è quantificare le performance predittive dei modelli e assicurare che si generalizzino su dati nuovi.

Per problemi di **regressione** le misure tipiche includono:

- L'errore quadratico medio **(MSE)** ...
- ... la sua radice **(RMSE)**
- L'errore assoluto medio **(MAE)**

Questi indicatori misurano la deviazione media tra i valori effettivi e quelli predetti, penalizzando in modo generale gli errori grossolani.

Per problemi di **classificazione** vengono invece utilizzate le metriche:

- **Accuracy**
- **Precision**
- **Recall**
- **F1-Score**

Oltre a fornire un riscontro statistico sugli errori commessi dai modelli, queste metriche standard **sono utilizzate anche per capire se e come un modello può essere impiegato in uno scenario reale**.

1.3.2 Limiti delle metriche

Queste metriche presentano dei limiti, naturalmente compresi nel contesto in cui sono applicate: come già detto, il mercato finanziario è un ambiente dinamico dove grandi quantità di dati vengono generate ogni giorno.

Inoltre, le metriche non sono capaci di adattarsi al verificarsi di eventi esterni (come guerre, crisi, dazi, ...), portando a errori nelle predizioni in momenti di alta volatilità, che a loro volta generano errori nelle fasi successive poiché queste previsioni errate producono "precedenti" su cui si baseranno le previsioni future.

Infine, le metriche possono risultare fuorvianti se le classi sono sbilanciate o vi sono stati bias nel training del modello.

2 Protocollo sperimentale

2.1 Setup sperimentale

Il setup sperimentale del sistema si basa su una pipeline ben definita che include le fasi di preprocessing dei dati, addestramento del modello e valutazione delle prestazioni.
Ogni esperimento viene condotto mantenendo costanti le condizioni operative, al fine di isolare l'effetto delle scelte modellistiche sulle metriche di performance.

I modelli vengono addestrati utilizzando un insieme limitato di feature derivate dai dati OHLCV, in modo da ridurre la complessità e minimizzare il rischio di overfitting, scelta coerente con l'obiettivo accademico del progetto, che privilegia la chiarezza metodologica rispetto alla massimizzazione delle prestazioni assolute.

2.2 Strategia di split

Per stimare la capacità di generalizzazione, i dati disponibili vengono divisi in insiemi di addestramento e test.
I modelli vengono allenati sui dati di training e poi valutati sul test set, che funge da proxy per dati futuri reali.

Questo split train-test semplice è la forma più immediata adottata per la validazione dei modelli, inoltre, durante la validazione, è stata posta attenzione all'overfitting: un modello troppo complesso può adattarsi eccessivamente ai dettagli del training set, ottenendo un errore molto basso nel training ma prestazioni degradate sul test.

A differenza di un contesto statico, nel contesto finanziario l'ordine temporale delle osservazioni è importante nella raccolta dei dati.
Per questo motivo, viene adottato uno split temporale tra training-set e test-set, evitando mescolamenti casuali che porterebbero a data leakage.

I modelli vengono addestrati esclusivamente su dati storici precedenti e valutati su un intervallo temporale successivo, simulando uno scenario realistico in cui le previsioni sono effettuate su dati futuri non osservati, fornendo una stima più affidabile e realistica della capacità di generalizzazione dei modelli.

2.3 Riproducibilità dell'esperimento

2.3.1 Ambiente sperimentale

L'esperimento è stato condotto in un Jupyter Notebook, un ambiente interattivo ampiamente diffuso nella comunità data science, integrando codice, visualizzazioni e commenti, permettendo di documentare passo-passo il processo e di riprodurlo esattamente.

2.3.2 Librerie e strumenti utilizzati

Le principali librerie e strumenti utilizzati sono:

- **Pandas:** per la manipolazione e l'analisi dei dati;
- **NumPy:** per il calcolo numerico e la gestione degli array;
- **Seaborn:** per la generazione delle confusion matrix e delle correlation matrix;
- **Matplotlib:** per la rappresentazione grafica dei risultati;
- **Yfinance:** per estrarre i dati finanziari storici dal database di Yahoo Finance;
- **Scikit-learn:** per l'implementazione dei modelli di ML e le metriche di valutazione standard;
- **KNeighborsRegressor/RandomForestRegressor:** per le operazioni di regressione;
- **RandomForestClassifier/DecisionTreeClassifier:** per la classificazione.

2.4 Struttura sperimentale

L'esperimento è stato eseguito secondo un flusso sperimentale lineare:

1 preparazione dei dati

2 split in training e test set

3 preprocessing dei dati e addestramento dei modelli

4 valutazione con le metriche

I dati vengono divisi in set di training e test utilizzando split temporale (senza shuffle) per rispettare l'ordine cronologico.
Il preprocessing viene applicato dopo la suddivisione per isolare il test set e si utilizza una pipeline di scikit-learn che concatena normalizzazione e modellazione.

La normalizzazione delle feature è necessaria perché modelli come KNN sono sensibili alla scala delle variabili, quindi lo scaler viene adattato sul training set e poi applicato al test set, evitando perdite di informazione.

Infine, nelle fasi di training e valutazione:

- **Regressione:** KNN Regressor, Random Forest Regressor e Gradient Boosting Regressor, valutati in base alle metriche MAE e MSE;
- **Classificazione:** Random Forest, Decision Tree e Naive Bayes, tutti valutati in base a Accuracy, Precision, Recall e F1-Score.

Random Forest è un ensemble di molti alberi decisionali: combinando più alberi su sottoinsiemi dei dati, viene aumentata l'accuratezza e ridotto l'overfitting.

2.5 Riproducibilità

La riproducibilità è garantita fissando un seme pseudo-casuale (random_state) nella divisione train-test e nei costruttori dei modelli, così ogni esecuzione del notebook produce gli stessi split dei dati e le medesime predizioni.

L'intero flusso codificato in un unico notebook permette di conservare l'ordine di esecuzione, i dati utilizzati e i risultati intermedi.

3 Confronto tra i modelli

Nel progetto, modelli diversi vengono confrontati secondo il protocollo sperimentale prima definito, garantendo che le differenze nelle prestazioni siano dovute alle scelte modellistiche e non a variazioni nello split dei dati o nel preprocessing.

Di seguito cominciamo col giustificare le scelte dei modelli utilizzati nel progetto.

3.1 Selezione dei modelli e scelte strutturali

La scelta dei modelli di regressione e classificazione è stata motivata dalle caratteristiche specifiche dei dati finanziari:

3.1.1 Regressione

Il **KNN Regressor** è utile per catturare relazioni locali e pattern presenti nei dati e viene utilizzato come baseline non parametrica per la valutazione di modelli più complessi.

Questo modello predice il valore di output come media dei K vicini più prossimi nel training set ed è particolarmente sensibile alla scala delle feature, motivo per cui la normalizzazione è fondamentale.
Il costo computazionale è basso durante il training ma tende ad aumentare con il numero di osservazioni durante la fase di inferenza.

Come nel caso della classificazione, abbiamo pensato di adottare due approcci ensemble anche nella regressione, introducendo il **Gradient Boosting Regressor (GBR)** si possono catturare relazioni non lineari complesse tra features e target, mentre con il **Random Forest Regressor** abbiamo analizzato il comportamento di un ensemble Random Forest anche su task di regressione, comparativamente ai task di classificazione.

Il GBR è molto adatto al nostro contesto poiché combina sequenzialmente più modelli deboli per correggere progressivamente gli errori commessi nelle iterazioni precedenti, risultando più flessibile rispetto al KNN Regressor ma anche più sensibile agli iperparametri selezionati per il modello (come numero di stimatori e profondità massima degli alberi decisionali), sacrificando però l'interpretabilità delle predizioni effettuate.

Questi tre modelli ci permetteranno di analizzare un approccio basato sulle relazioni locali nei dati e un approccio basato sulla modellazione incrementale e non lineare degli errori.

3.1.2 Classificazione

Il **Naive Bayes** è stato scelto per la sua capacità di funzionare bene su dati rumorosi e distribuiti in modo variabile, offrendo anche indipendenza tra le feature, è molto veloce sia in fase di training sia di inferenza, ma le assunzioni semplificative possono limitare le performance quando le feature sono altamente correlate.
Questo modello serve a valutare l'efficacia di un approccio probabilistico rispetto a modelli ad albero come Decision Tree e Random Forest.

3.2 Criteri di confronto

Il confronto tra modelli non si basa su una sola metrica, ma su vari aspetti rilevanti della performance predittiva nel contesto finanziario.

3.2.1 Accuratezza predittiva

Per la **regressione**, si utilizzano MAE e MSE: MAE misura l'errore medio lineare, mentre MSE penalizza maggiormente errori estremi, distinguendo errori sistematici e deviazioni importanti.

Per la **classificazione**, l'accuracy indica la correttezza generale delle predizioni direzionali, contestualizzata rispetto alla distribuzione delle classi e alla stabilità temporale dei risultati.

3.2.2 Stabilità e Robustezza

Per **stabilità** si intende la capacità del modello di produrre risultati coerenti al variare dei dati di training o dei periodi temporali analizzati.

Un modello instabile, come un singolo Decision Tree, può produrre predizioni molto diverse se addestrato su sottoinsiemi leggermente differenti del dataset. Al contrario, un ensemble come **Random Forest** riduce la varianza aggregando i risultati di più alberi, aumentando così la coerenza predittiva.

La **robustezza** riguarda la resistenza del modello a rumore, outlier o cambiamenti improvvisi nei dati.
Modelli non parametrici basati sulla distanza, come il KNN Regressor, possono essere sensibili a valori anomali, mentre modelli basati su aggregazioni o regolarizzazioni, come il Random Forest, risultano più resilienti a perturbazioni locali nei dati.

Valutare stabilità e robustezza significa quindi non limitarsi all'accuratezza globale, ma analizzare come le performance variano su diversi periodi temporali o sotto differenti condizioni di mercato, permettendoci di scegliere modelli affidabili, capaci di mantenere performance consistenti anche in scenari finanziari volatili.

4 Analisi degli errori

In finanza, un singolo errore può avere conseguenze significative, pertanto la comprensione qualitativa degli errori, la loro frequenza e il loro impatto sono elementi indispensabili per guidare la scelta dei modelli, l'ingegneria delle feature e eventuali strategie di mitigazione del rischio.

Per analizzare gli errori useremo stromenti come le confusion matrix, che ci consentono di distinguere tra veri positivi, veri negativi, falsi positivi e falsi negativi, fornendo una rappresentazione dettagliata delle performance oltre le metriche aggregate come l'accuratezza.
Nel contesto specifico della previsione dei movimenti di mercato, un falso positivo corrisponde a prevedere un rialzo che non si verifica (errore di tipo I), mentre un falso negativo corrisponde a non prevedere un rialzo reale (errore di tipo II).

La rilevanza di ciascun tipo di errore è influenzata dalla natura del mercato: un falso negativo può comportare la perdita di opportunità di investimento e la sottovalutazione di segnali di trend positivo, mentre un falso positivo può portare a decisioni speculative errate, con conseguenti perdite finanziarie.

Per superare i limiti imposti dalle metriche tradizionali, l'analisi include l'utilizzo di indici bilanciati come l'F1-score, che combina precision e recall, fornendo una misura più equilibrata della capacità del modello di distinguere tra le classi.

L'osservazione della distribuzione degli errori nella confusion matrix permette inoltre di identificare pattern ricorrenti, come la tendenza dei modelli a predire più frequentemente rialzi rispetto ai ribassi o a smorzare le previsioni in corrispondenza di picchi di volatilità.

5 Trade-off e Limiti

Come introdotto nella sezione 3, i modelli utilizzati sono stati frutto di scelte basate sulla natura intrinseca del mercato finanziario, scelte che hanno portato a compromessi nelle previsioni finali fornite negli output.

5.1 Interpretabilità vs. Stabilità

Un modello come il KNN Regressor, che ricordiamo essere la nostra baseline di valutazione, offre molta flessibilità sui dati, adattandosi velocemente a pattern locali, dimostrando però instabilità alla presenza di outlier nel dataset.

Al contrario, il Gradient Boosting Regressor utilizza un approccio più strutturato e robusto, consentendo di ottenere previsioni generalmente più stabili e accurate, riducendo però significativamente l'interpretabilità: il modello non fornisce una rappresentazione immediata del contributo delle singole variabili, rendendo più complessa l'analisi dei risultati.

Notiamo un trade-off simile anche nella implementazione dei Decision Tree: singolarmente sono facilmente interpretabili ma rischiano bias dovuti all'eccessivo rumore, per questo motivo applichiamo il modello di Random Forest, aumentando l'accuratezza, la robustezza e diminuendo l'overfitting, sacrificando però l'interpretabilità.

5.2 Semplicità vs. Accuratezza

Questo è il trade-off più presente nei progetti di questo tipo, ovviamente dei modelli più complessi porteranno a previsioni più precise poiché le scelte prese dal modello di ML sono dovute a più variabili.
Considerando che il progetto è di natura accademica, la complessità dei modelli è limitata al minimo, garantendo comunque la riuscita del progetto.

Esempi di questo trade-off si possono notare nella scelta del Decision Tree, modello complesso ma facilmente interpretabile, un modello performante ma tendente all'overfitting, oppure nel Naive Bayes modello decisamente più semplice ma contemporaneamente efficace, anche se degradato dalla correlazione tra feature, o ancora nel Gradient Boosting regressor, più flessibile e preciso del KNN Regressor ma con risultati meno interpretabili.

Considerare modelli con proprietà così differenti consente quindi di valutare non solo quale algoritmo sia migliore in base alle metriche di performance, ma anche quale offra il miglior equilibrio tra capacità predittiva, stabilità e interpretabilità.

6 Riepilogo e Conclusioni

6.1 Definizione del problema e del contesto applicativo

Nel corso di questo progetto è stato analizzato il comportamento di diversi modelli di ML applicati alla previsione di serie temporali finanziarie, un contesto non stazionario caratterizzato da elevata complessità, forte rumore nei dati ed elevata volatilità.
L'obiettivo principale non è stato esclusivamente ottenere le migliori prestazioni predittive, ma piuttosto comprendere come differenti scelte modellistiche influenzino l'accuratezza, la stabilità e l'affidabilità delle previsioni.

6.2 Analisi delle metriche, delle feature e del dataset

Attraverso l'utilizzo di un dataset finanziario costruito a partire da dati storici OHLCV e arricchito con feature derivate dall'analisi tecnica (come momentum, medie mobili, volatilità e RSI) è stato possibile costruire un ambiente sperimentale coerente per valutare sia modelli di regressione sia modelli di classificazione.
L'impiego di algoritmi con caratteristiche differenti, come KNN Regressor e Gradient Boosting Regressor per la regressione, e Naive Bayes, Decision Tree e Random Forest per la classificazione, ha permesso di analizzare concretamente i trade-off tra interpretabilità, complessità e capacità predittiva.

L'analisi delle metriche di valutazione e delle matrici di confusione ha evidenziato come le prestazioni dei modelli non possano essere interpretate unicamente attraverso indicatori numerici globali.
In un contesto finanziario, infatti, la distribuzione degli errori e la stabilità delle predizioni nel tempo assumono un ruolo altrettanto rilevante.

Un modello molto accurato in media può risultare meno affidabile se mostra forte variabilità in presenza di dati rumorosi o condizioni di mercato particolarmente volatili.
I risultati ottenuti mostrano come modelli più semplici e interpretabili, come il Naive Bayes o il Decision Tree, offrano un buon punto di riferimento metodologico e consentano una comprensione più chiara delle relazioni tra le variabili.

6.3 Analisi dei trade-off e limiti applicativi

Allo stesso tempo, modelli più complessi, come Random Forest, dimostrano una maggiore robustezza rispetto al rumore e alle variazioni nei dati, sebbene al costo di una minore interpretabilità e di una maggiore complessità computazionale.

L'analisi dei trade-off tra interpretabilità, accuratezza, stabilità e complessità computazionale evidenzia quindi che non esiste un modello universalmente migliore per questo tipo di problema, la scelta del modello dipende piuttosto dal contesto applicativo e dagli obiettivi dell'analisi, che possono privilegiare la trasparenza delle decisioni, la velocità computazionale o la massima capacità predittiva.

6.4 Sviluppi futuri

In prospettiva futura, il lavoro potrebbe essere esteso introducendo tecniche di validazione temporale più avanzate, un numero maggiore di feature finanziarie o modelli di apprendimento più complessi, con l'obiettivo di migliorare ulteriormente la capacità dei sistemi di ML di interpretare e prevedere le dinamiche dei mercati finanziari.

In conclusione, il progetto dimostra come anche modelli relativamente semplici, se applicati all'interno di una pipeline metodologicamente corretta e accompagnati da un'analisi critica delle metriche e degli errori, possano fornire risultati significativi e costituire una base solida per studi successivi.