Easy Finances AI

Problem Statement

Francesco Castagnozzi, Vincenzo Mauro

12/01/2026

link repository Github del progetto:
https://github.com/Memento0Mori/easy-finances-AI/tree/main

questa pagina è intenzionalmente lasciata vuota

Sommario

1 Introduzione al progetto **4**

2 Specifica dell'ambiente - PEAS **4**
2.1 Performance measure 4
2.2 Environment 5
2.3 Actuators 5
2.4 Sensors 5

3 Definizione e approcci al problema **6**

4 Definizione e origine del dataset **7**

5 Objective & Success Criteria **8**
5.1 Obiettivi del progetto 8
5.2 Criteri di successo 8
5.2.1 Valutazione quantitativa dei modelli 8
5.2.2 Valutazione metodologica dei modelli 8

6 Vincoli e limitazioni del progetto **9**

7 Ambiti e confini del progetto **9**

1 Introduzione al progetto

Easy Finances AI è un progetto di finanza quantitativa che si propone di analizzare e prevedere il comportamento a breve termine di un titolo azionario mediante tecniche di Machine Learning.

Il progetto si affiderà ad alcune parti del processo CRISP-DM per assicurare un approccio strutturato: partendo da Business & Data Understanding, Data Preparation e Modeling & Evaluation.

I dati considerati includeranno serie storiche di prezzo (open/high/low/close), volume e indicatori tecnici derivati; le analisi prenderanno in considerazione finestre temporali adeguate per il training dei modelli di Machine Learning che si andranno ad utilizzare, oltre all'uso tecniche per evitare bias temporali.
Il problema viene quindi interpretato come un problema di Intelligenza Artificiale in cui un agente predittivo opera in un ambiente complesso e parzialmente osservabile.

2 Specifica dell'ambiente - PEAS

In questa sezione del documento trattiamo la parte PEAS, per specificare l'ambiente in cui opereranno i modelli proposti.

2.1 Performance measure

Le metriche di prestazione utilizzate nel progetto riguarderanno il rendimento dei modelli di Machine Learning nei propri task rispettivi di classificazione e regressione.
Le metriche principali per il modello di regressione sono MAE, MSE e RMSE, mentre per il modello di classificazione verranno adottate misure di Recall, Precision, Accuracy e F1-Score. Tutte le metriche verranno trattate dettagliatamente nella sezione 4.2 del documento.

2.2 Environment

L'ambiente in cui si opera è rappresentato dal mercato azionario, modellato tramite serie temporali storiche relative a un singolo titolo finanziario.
Secondo la classificazione proposta da Russell & Norvig, tale ambiente può essere caratterizzato come:

- **parzialmente osservabile:** l'agente dispone solo di una porzione incompleta dello stato reale del mercato, limitandosi a dati storici di prezzo, volume e altri indicatori tecnici.
- **stocastico:** l'evoluzione dell'ambiente non è deterministica e presenta una natura aleatoria non eliminabile.
- **dinamico:** lo stato dell'ambiente evolve nel tempo indipendentemente dalle azioni dell'agente.
- **sequenziale:** ogni previsione dipende da una sequenza di osservazioni precedenti.
- **continuo** nello spazio degli stati e nel tempo.

È importante sottolineare che l'agente non esercita alcuna influenza sull'ambiente, il sistema si limita a osservare e a formulare previsioni, senza eseguire azioni che possano modificare lo stato del mercato.

2.3 Actuators

Nel contesto del progetto, gli attuatori non riguardano azioni dirette sul mercato ma si limitano all'output di previsioni
Il loro ruolo consiste nella generazione di una stima numerica della variazione percentuale del prezzo del titolo nel giorno successivo (regressione) oppure nell'assegnazione di una classe predittiva che indica la direzione del movimento del titolo (classificazione).
Tali output sono destinati esclusivamente a fini di analisi, valutazione e dimostrazione del funzionamento del sistema, senza implicare decisioni operative di trading.

2.4 Sensors

I sensori del progetto sono costituiti dai dati finanziari storici che l'agente usa per effettuare previsioni.
L'agente riceve in input serie temporali di prezzi (come high/open/low/close) e volumi di scambio, oltre ad altri indicatori tecnici ricavati da finestre temporali prefissate.

3 Definizione e approcci al problema

Il problema affrontato nel progetto consiste nella previsione del comportamento a breve termine dei titoli azionari di una o più specifiche organizzazioni prese in esame.

Questo progetto consente di analizzare e confrontare il comportamento di diversi approcci di Machine Learning in un contesto realistico e complesso come quello finanziario, ponendo particolare attenzione alla capacità di generalizzazione dei modelli e alla loro robustezza su dati non stazionari.

Sui dati finanziari storici degli ultimi 10 anni dell'organizzazione, verranno utilizzate tecniche di apprendimento supervisionato per addestrare un modello di ML in modo da renderlo capace di stimare la variazione percentuale del titolo nel giorno successivo in base a ciò che viene osservato precedentemente.
Formalmente, il dataset è costituito da una serie temporale finanziaria così definita:

$$\{X_t\}_{t=1}^{T}$$

dove ogni componente della serie X_t rappresenta lo stato del mercato al tempo t ed è descritta da feature derivate dai dati storici di prezzo (come open, high, low, close), volumi di scambio e indicatori valutati in finestre di tempo appropriate.
Come detto prima, l'orizzonte temporale di osservazione è di 10 anni, mentre l'orizzonte di previsione è fissato a un giorno (h = 1).

Inoltre, è stata definita una variabile custom che quantifica la variazione percentuale del titolo nel giorno t+1: **Target_Return**. Questa variabile viene utilizzata in due formulazioni del problema:

- **Regressione:** i modelli apprendono una funzione che stima la variazione percentuale definita come

  $$f_\theta : X_t \to \mathbf{R}$$

  Per questo tipo di modello verranno utilizzate metriche di errore quali RMSE e MAE per valutare i dati generati.

- **Classificazione:** i modelli apprendono una funzione, di seguito definita

  $$g_\theta : X_t \to \mathbf{C}$$

  che prevede la direzione del movimento in borsa (up/down), etichettando il valore in base ai dati originali e sui valori predetti nella regressione. Questo modello verrà valutato con le classiche metriche di valutazione Precision, Accuracy, Recall e F1-score.

4 Definizione e origine del dataset

Il dataset utilizzato nel presente progetto è stato costruito a partire da dati finanziari storici relativi a cinque grandi aziende del settore tecnologico:
Google, Meta, Apple, Microsoft e Amazon
I dati coprono un intervallo temporale di dieci anni, dal 2015 al 2025, permettendo di analizzare l'evoluzione dei titoli in diversi contesti di mercato.

Per ciascun asset sono state considerate le principali variabili di mercato, comunemente note come OHLCV (Open, High, Low, Close, Volume). In particolare:

- **Open:** indica il prezzo di apertura giornaliero
- **High/Low:** rispettivamente il massimo e il minimo raggiunti durante la giornata
- **Close:** rappresenta il prezzo di chiusura della giornata
- **Volume:** il numero di transazioni effettuate su quel titolo durante la giornata

Queste informazioni costituiscono la base per la costruzione del dataset e per le successive fasi di analisi e modellazione.
L'utilizzo di più asset consente di ottenere un dataset multi-asset, che riflette in modo più realistico la variabilità del mercato e introduce una maggiore eterogeneità nei pattern osservati.

I dati sono stati raccolti dal database di Yahoo Finance e successivamente integrati in un unico dataset coerente, mantenendo l'ordine temporale delle osservazioni, questa struttura consente di preservare la natura sequenziale delle serie storiche, elemento fondamentale per garantire la validità delle analisi e delle tecniche di ML applicate.

5 Objective & Success Criteria

5.1 Obiettivi del progetto

Il progetto Easy finances AI non si propone di sviluppare un prodotto capace di prevedere i movimenti del mercato azionario, il nostro è un progetto accademico, mirato a studiare e sviluppare modelli di regressione e classificazione utilizzando approcci di machine learning differenti.

Inoltre, verranno valutate le capacità generative dei modelli su dati temporali non utilizzati durante il training, la robustezza delle prestazioni rispetto a lievi cambiamenti negli intervalli temporali di test. Infine, verrà applicato il processo CRISP-DM, garantendo tracciabilità e una corretta metodologia.

5.2 Criteri di successo

5.2.1 Valutazione quantitativa dei modelli

- **Regressione:** i modelli di regressione saranno considerati efficaci nel momento in cui i valori del RMSE e del MAE risultano inferiori alle baseline di riferimento.
- **Classificazione:** per i modelli di classificazione la valutazione avverrà riferendosi alle metriche Precision, Recall, Accuracy e F1-Score, ad altre metriche custom (definite nel M.E.T.A.D.) e sul bilanciamento tra classi e features.

Infine, le prestazioni saranno stimate con dei test basati su dati non presenti nel dataset di training, simulando una previsione effettuata con dati "reali".

5.2.2 Valutazione metodologica dei modelli

Il progetto avrà successo nel momento in cui verranno evitati fenomeni di leakage informativo e bias temporali, entrambi raggiungibili utilizzando procedure di validazione adeguate alle serie temporali.

I modelli scelti e i risultati sperimentali da loro generati saranno analizzati in modo critico, evidenziando eventuali instabilità, errori e limiti.
La valutazione del successo del progetto quindi non si atterrà solo al raggiungimento di specifici valori metrici, ma riguarderà anche la coerenza dell'analisi e la consapevolezza dei limiti della previsione finanziaria.

6 Vincoli e limitazioni del progetto

Il progetto è soggetto ad una serie di vincoli intrinseci del mercato azionario e al dominio finanziario che sono fuori dal controllo dei progettisti.
Di seguito questi vincoli definiscono chiaramente l'ambito del progetto e ne circoscrivono i risultati al fronte di evita misinterpretazioni degli stessi:

- **Caoticità dell'ambiente:** i dati utilizzati riflettono un contesto di mercato caratterizzato da elevato rumore, non stazionarietà e possibili cambi di regime, questo ambiente caotico limita la capacità dei modelli di apprendere relazioni stabili e generalizzabili nel tempo, favorendo la comparsa di bias ed errori nelle previsioni.
- **Fattori esterni non considerati:** l'analisi dei dati si basa esclusivamente su informazioni storiche di prezzo, volume e indicatori tecnici derivati, dati facilmente ottenibili e non influenzati da fattori esogeni quali notizie macroeconomiche, eventi societari o dinamiche geopolitiche, che possono influenzare significativamente l'andamento dei titoli azionari e il comportamento del mercato.
- **Limiti metodologici:** l'orizzonte di previsione è limitato ad un solo giorno e le prestazioni dei modelli sono valutate con dei test out-of-sample che, pur garantendo una stima più realistica della capacità di generalizzazione, non eliminano l'incertezza intrinseca del problema.

7 Ambiti e confini del progetto

L'ambito del progetto è definito sull'analisi metodologica e sperimentale di tecniche di Intelligenza Artificiale supervisionata per la previsione a breve termine di un titolo azionario, escludendo volutamente tutti gli aspetti che non rientrano negli obiettivi del lavoro.

Il progetto non affronterà aspetti come l'ottimizzazione automatica degli iperparametri su larga scala, la selezione automatica dei modelli o l'uso di approcci di apprendimento online, ma si limiterà ad un contesto accademico di addestramento e valutazione.

Altri confini del progetto riguardano l'assenza di analisi approfondite sulla sensibilità delle feature, la mancata esplorazione di tecniche avanzate di riduzione della dimensionalità o di interpretabilità dei modelli, e la non considerazione di aspetti etici, normativi o socio-economici legati all'uso di sistemi predittivi in finanza. Queste scelte permettono di concentrarsi sugli aspetti fondamentali dell'apprendimento supervisionato e sul confronto controllato tra modelli, chiarendo che i risultati devono essere interpretati solo all'interno del contesto metodologico e sperimentale definito dal progetto.